Własności-szeregu-zwrotów-logarytmicznych-spółki-Volkswagen-z-okresu-2018-2021

April 3, 2024

1 Własności szeregu zwrotów logarytmicznych spółki Volkswagen z okresu 2018-2021

Ten raport mozna również znaleźć w interaktywnej formie tutaj:

- Nazwa akcji: Volkswagen AG
- Skrót dla akcji: VOW.DE
- Branża: Motoryzacyjna - koncern motoryzacyjny

1.1 Historia:

Koncern powstał w 1937 roku na gruncie potrzeby produkcji taniego, rodzinnego samochodu którą Adolf Hitler przedłożył Ferdinandowi Porche, nadwornemu konstruktorowi nazistowskich Niemiec. W 1938 roku do seryjnej produkcji został oddany pierwszy model VW populary "Garbus", a fabryka KdF-Wagen wykorzystywała robotników przymusowych i więźniów obozów koncentracyjnych.

W kolejnych dekadach Volkswagen rozwijał się, a w 1991 roku rozpoczęto ekspansję w nowe kierunki, takie jak otwarcie spółki w Chinach i Polsce. Powstała również Volkswagen Finanz GmbH, oferująca usługi finansowe. W 1998 roku koncern utworzył fundusz pomocy dla byłych robotników przymusowych.

W XXI wieku Volkswagen kontynuował ekspansję i inwestycje, jak np. Autostadt w 2000 roku oraz przejęcie przez MAN SE spółki Volkswagen Caminhões e Ônibus w 2009 roku. Jednakże w 2015 roku koncern został wstrząśnięty aferą dotyczącą manipulacji wynikami pomiarów emisji w swoich pojazdach tzw. Diesel Gate, Mimo to, Volkswagen nadal odgrywa znaczącą rolę w przemyśle motoryzacyjnym, będąc także sponsorem klubu piłkarskiego VfL Wolfsburg.

1.2 Wydarzenia mające wpływ na notowania spółki w danym okresie (2018-2021)

Na wykresie widzimy znaczącą wyprzedaż akcji koncernu skutującą obniżeniem wyceny jej akcji na skutek pandemii COVID19 która przypadała na marzec 2020. Następnie w okresie kwiecień 2020 - kwiecień 2021 na skutek stymulusu fiskalnego i zapomóg pandemicznych, globalnie giełdy notowały wzrosty co również przełożyło się na wzrost cenę akcji VW. Ostatecznie od kwietnia 2021 widzimy efekt podwyżki stóp procentowych i odpływ kapitału z giełd co przekłada się na kolejną korektę i obniżenie ceny akcji koncernu Volkswagen.

[1]:
```python
import pandas as pd
data = pd.read_csv("https://stooq.pl/q/d/l/?s=vow3.
 ↪de&d1=20180101&d2=20211231&i=d", parse_dates=["Data"])
data.head()
```

[1]:

	Data	Otwarcie	Najwyzszy	Najnizszy	Zamkniecie	Wolumen
0	2018-01-02	130.912	131.163	126.737	130.049	1.533116e+06
1	2018-01-03	130.677	134.946	130.425	134.554	1.657879e+06
2	2018-01-04	135.386	137.222	134.428	136.908	1.818363e+06
3	2018-01-05	138.525	141.021	138.368	140.644	2.552202e+06
4	2018-01-08	141.978	142.041	140.597	141.146	1.350856e+06

[2]:
```python
import matplotlib.pyplot as plt
from datetime import datetime
from dateutil.relativedelta import relativedelta


min_date = datetime.fromtimestamp(data["Data"].min().timestamp())
max_date = datetime.fromtimestamp(data["Data"].max().timestamp())
d = relativedelta(max_date, min_date)
quarters = d.years * 4 + d.months // 3 + 1
x_ticks = [min_date + relativedelta(months=3*i) for i in range(quarters+1)]


fig, ax = plt.subplots(figsize=(20, 9))
ax.plot(data["Data"], data["Zamkniecie"], label="Kursy zamknięcia VW")
ax.legend()
ax.set_xticks(x_ticks)
plt.show()
```

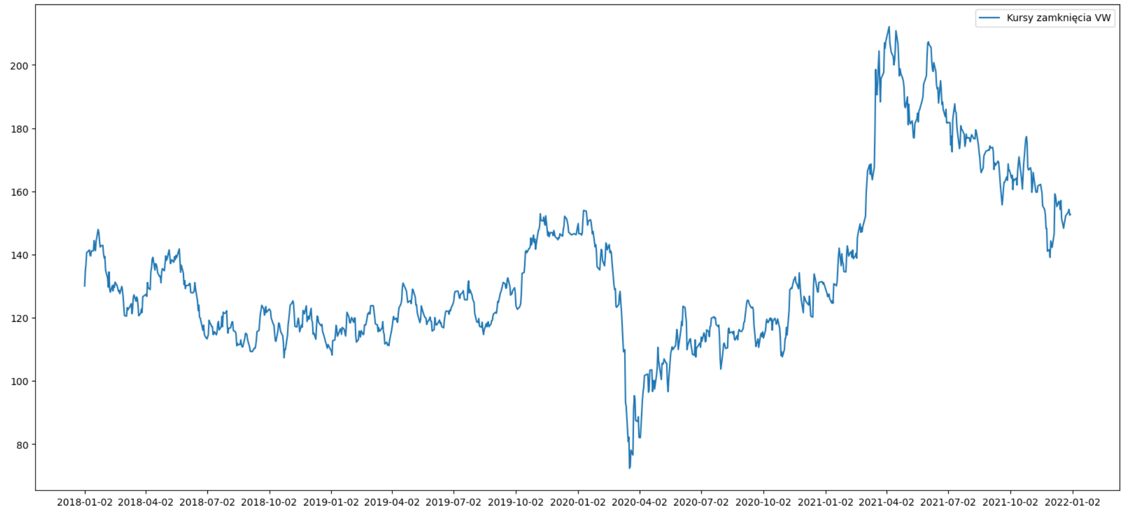

[3]:
```
import numpy as np

def make_stationary(x:np.ndarray):
    # return 100 * (x[1:] - x[:-1])
    return 100 * (np.log(x[1:]) - np.log(x[:-1]))

log_returns = make_stationary(data["Zamkniecie"].values)

import matplotlib.pyplot as plt
fig, ax = plt.subplots(figsize=(20, 8))
ax.plot(data.loc[1:, "Data"], log_returns, label="Logarytmiczne zwroty VW")
ax.legend()
ax.set_xticks(x_ticks)
plt.show()
```

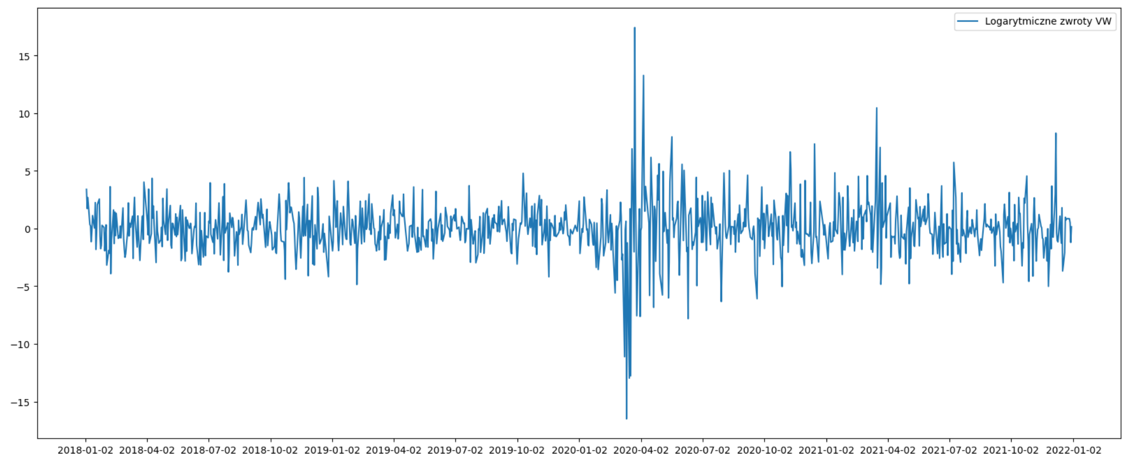

Zgodnie ze wcześniejszym opisem widzimy znaczący wzrost zmienności zwrotów w okresie przypadającym na wybuch pandemii COVID19.

1.3 Statystyki opisowe

[4]:
```
log_returns = pd.DataFrame(log_returns, columns=["Logartymiczne zwroty VW"])
log_returns.describe()
```

[4]:
```
       Logartymiczne zwroty VW
count              1009.000000
mean                  0.015916
std                   2.300384
min                 -16.501493
25%                  -1.108679
50%                  -0.012921
75%                   1.055295
```

```
max                    17.433991
```

Średnia logarytmicznych zwrotów w badanym okresie wynosi 0.015 co oznacza, że w rozważanym okresie średnio wzrost ceny spółki przewyższał spadki co odzwierciedla również wyższa cena instrumentu na koniec badanego okresu w porównaniu z jego początkiem.

1.3.1 Współczynnik zmienności

[5]:
```python
log_returns.std() / log_returns.mean()
```

[5]:
```
Logartymiczne zwroty VW    144.529029
dtype: float64
```

1.3.2 Skośność i Kurtoza nadwyżkowa

[6]:
```python
log_returns.skew().values[0], (log_returns.kurtosis() - 3).values[0]
```

[6]:
```
(-0.00945022835761155, 6.702335837462236)
```

Rozkład charakteryzuje się małą skośnością, masa prawdopodobieństwa rozkłada się w okolicach średniej, natomiast ze względu na wysoką wartość kurtozy nadwyżkowej możemy wnioskować o leptokurtyczności rozkładu logarytmicznych zwrotów, co przekłada się na większą ilość skrajnych zwrotów lub strat niż wynikało by to z rozkładu normalnego. Aby się o tym przekonać przeprowadzimy test Jarque-Bera'y

1.3.3 Brakujące obserwacje

[7]:
```python
log_returns.isna().sum()
```

[7]:
```
Logartymiczne zwroty VW    0
dtype: int64
```

1.3.4 Q3 - Q1

[8]:
```python
log_returns.quantile(0.75) - log_returns.quantile(0.25)
```

[8]:
```
Logartymiczne zwroty VW    2.163974
dtype: float64
```

1.4 Test Jarque'a-Bera'y

[9]:
```python
from statsmodels.stats.stattools import jarque_bera

test_statistic, p_value, skewness, kurtosis = jarque_bera(log_returns)
test_statistic[0], p_value[0], skewness[0], kurtosis[0]
```

[9]:
```
(3913.728096995842, 0.0, -0.009436173649672955, 12.648382937936523)
```

P-value dla statystyki testowej testu Jarque'a-Bera'y wynosi 0, co powoduje, że powinniśmy odrzucić hipotezę zerową o normalności rozkładu logarytmicznych zwrotów spółki VW.

1.5 Analiza histogramu i wykresu kwantyl kwantyl

[10]:
```
import numpy as np
import matplotlib.pyplot as plt
from scipy import stats

log_returns = log_returns["Logartymiczne zwroty VW"].values
N=len(log_returns)
x = stats.norm.rvs(size=N)
num_bins = 20
y = np.linspace(-4, 4, 1000)
bin_width = (x.max() - x.min()) / num_bins

fig, ax = plt.subplots(figsize=(10, 7))
ax.plot(y, stats.norm.pdf(y), color="b", label="Gęstość rozkładu normalnego")
ax.hist(x, density=True, bins=num_bins, facecolor='r', alpha=0.5,␣
 ↪label="Histogram próby z rozkładu normalnego")
ax.hist(log_returns, density=True, bins=3*num_bins, facecolor='g', alpha=0.5,␣
 ↪label="Histogram zwrotów logarytmicznych")
ax.legend()
plt.show()
```

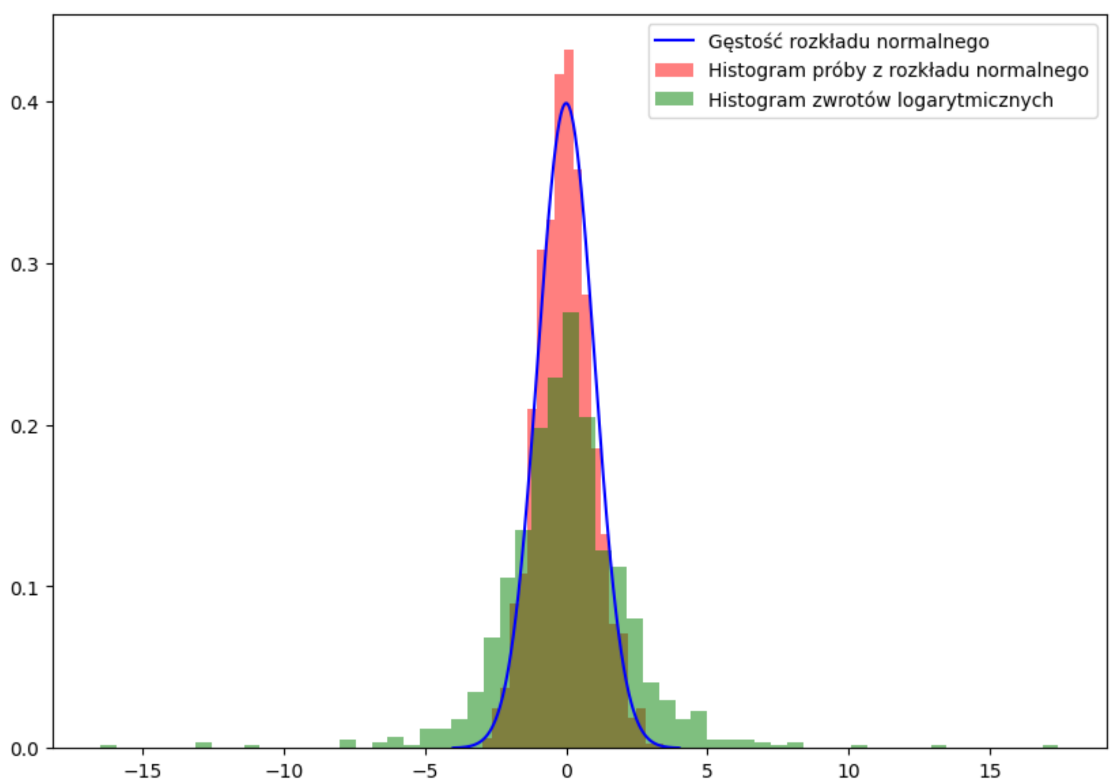

[11]:
```python
import statsmodels.api as sm

sm.qqplot(log_returns, line ='45')
plt.show()
```

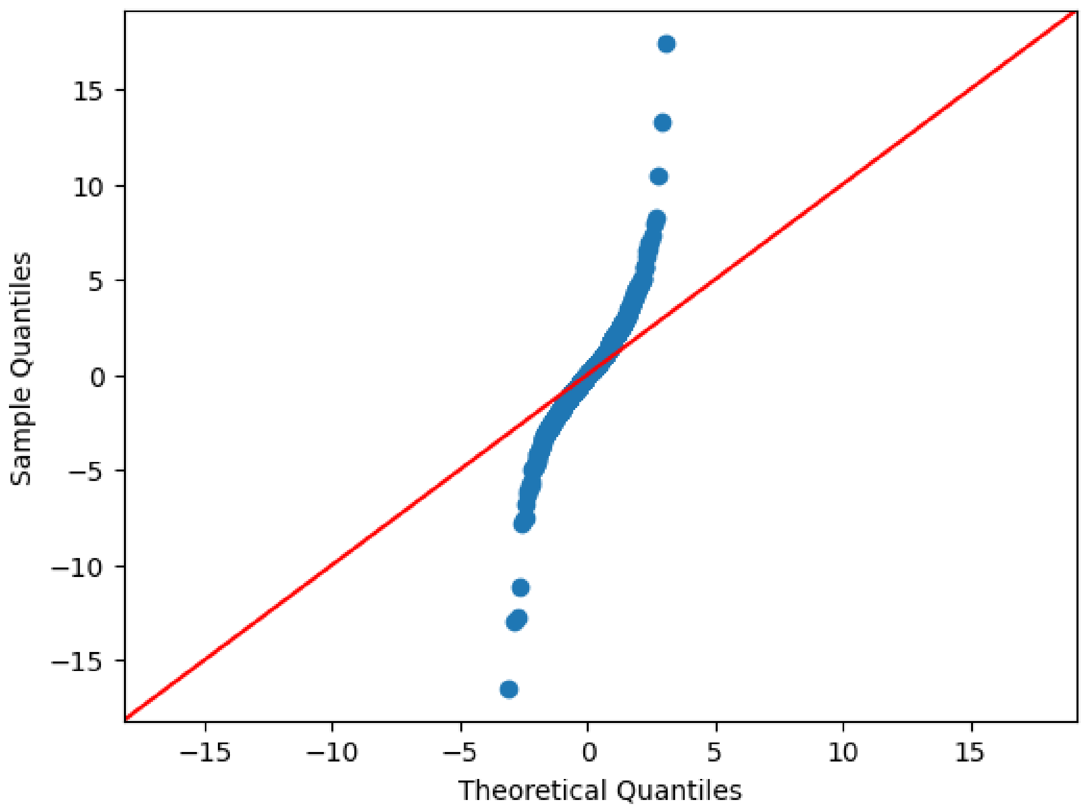

1.6 Analiza korelacji i korelacji częściowej dla szeregu zwrotów logarytmicznych wraz z wynikami testu Boxa-Pierce'a i Ljunga-Boxa

[12]:
```python
squared_log_returns = pd.Series(log_returns**2, name="squared log returns")
log_returns = pd.Series(log_returns, name="log returns")


log_returns_autocorr = np.array([(i, log_returns.autocorr(lag=i)) for i in␣
↪range(1,21)])
squared_log_returns_autocorr = np.array([(i, squared_log_returns.
↪autocorr(lag=i)) for i in range(1,21)])
```

[13]:
```python
import seaborn as sns
import statsmodels

ljungbox_boxpierce = statsmodels.stats.diagnostic.acorr_ljungbox(log_returns,␣
↪lags=list(range(1,21)), boxpierce=True, model_df=0, period=None,␣
↪return_df=True, auto_lag=False)
confidence = 0.95

both_tests_agree = ljungbox_boxpierce[(ljungbox_boxpierce["lb_pvalue"] >␣
↪1-confidence) & (ljungbox_boxpierce["bp_pvalue"] > 1-confidence)]
set(ljungbox_boxpierce[(ljungbox_boxpierce["bp_pvalue"] > 1-confidence)].index)␣
↪== set(ljungbox_boxpierce[(ljungbox_boxpierce["lb_pvalue"] > 1-confidence)].
↪index)
```

[13]: True

[14]:
```python
both_tests_agree
```

[14]:

	lb_stat	lb_pvalue	bp_stat	bp_pvalue
1	2.169953	0.140731	2.163514	0.141321
2	2.525771	0.282837	2.517924	0.283949
3	2.839434	0.417049	2.830036	0.418579
4	5.045224	0.282689	5.022735	0.284973
5	5.166099	0.395948	5.142773	0.398706

[15]:
```python
not_significant = np.array(sorted(list(set(ljungbox_boxpierce.index-1).
↪difference(set(both_tests_agree.index-1)))))
fig, ax = plt.subplots(figsize=(8,5))
sns.scatterplot(x=log_returns_autocorr[both_tests_agree.index-1,0],␣
↪y=log_returns_autocorr[both_tests_agree.index-1,1], label="Statystycznie␣
↪istotna autokorelacja logarytmicznych zwrotów", c="g", ax=ax)
sns.scatterplot(x=log_returns_autocorr[not_significant,0],␣
↪y=log_returns_autocorr[not_significant,1], label="Statystycznie nieistotna␣
↪autokorelacja logarytmicznych zwrotów", c="r", ax=ax)
ax.set_xticks(log_returns_autocorr[:,0])
ax.set_ylabel("Wartość autokorelacji")
ax.set_xlabel("Rząd korelogramu")
ax.set_ylim(-1.0, 1.0)
plt.show()
```

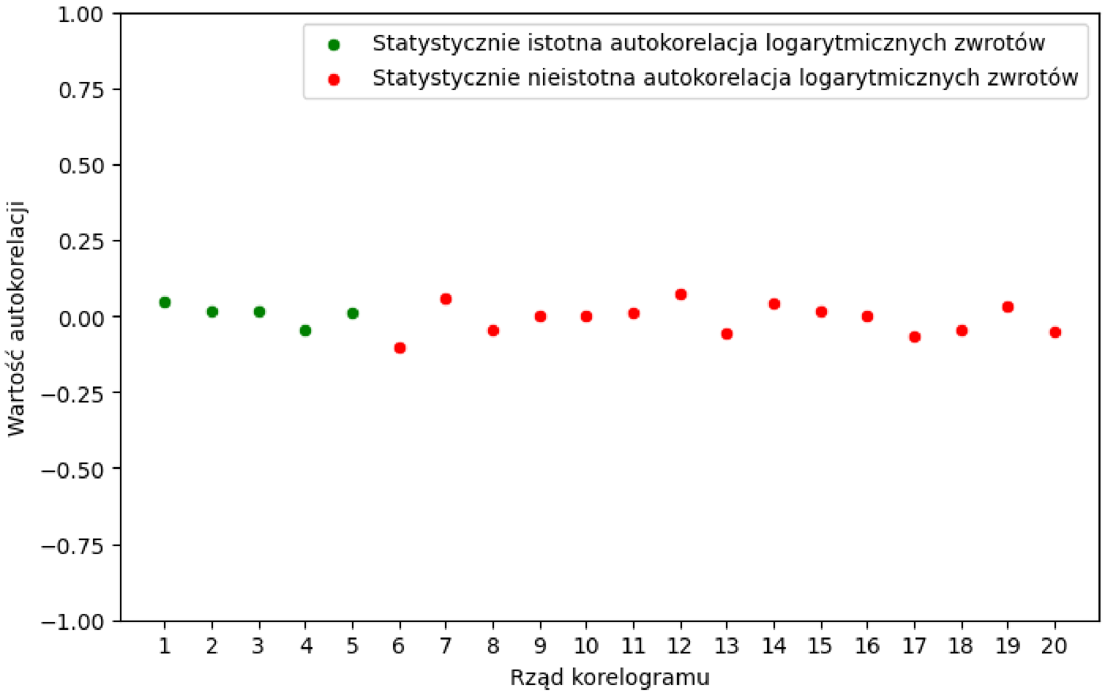

Jak widać tylko dla pierwszych pięciu wartości korelogramu są one istotne statystycznie. Jednakże jak dobrze widzimy dla wszystkich wartości autokorelacja oscyluje wokół zera, nie przekraczając co do absolutnej wartości wartości 0.25, co mówi nam, o znikomej liniowej relacji pomiędzy szeregiem logarytmicznych zwrotów a nim samym przesuniętym o określoną liczbe dni.

1.7 Analiza korelacji i korelacji częściowej dla szeregu kwadratów zwrotów logarytmicznych wraz z wynikami testu Boxa-Pierce'a i Ljunga-Boxa

[16]:
```
ljungbox_boxpierce = statsmodels.stats.diagnostic.
 ↪acorr_ljungbox(squared_log_returns, lags=list(range(1,21)), boxpierce=True,␣
 ↪model_df=0, period=None, return_df=True, auto_lag=False)
confidence = 0.95

both_tests_agree = ljungbox_boxpierce[(ljungbox_boxpierce["lb_pvalue"] >␣
 ↪1-confidence) & (ljungbox_boxpierce["bp_pvalue"] > 1-confidence)]
set(ljungbox_boxpierce[(ljungbox_boxpierce["bp_pvalue"] > 1-confidence)].index)␣
 ↪== set(ljungbox_boxpierce[(ljungbox_boxpierce["lb_pvalue"] > 1-confidence)].
 ↪index)
```

[16]: True

[17]:
```
both_tests_agree
```

[17]:

	lb_stat	lb_pvalue	bp_stat	bp_pvalue
1	0.866426	0.351947	0.863855	0.352662

[18]:
```
not_significant = np.array(sorted(list(set(ljungbox_boxpierce.index-1).
↪difference(set(both_tests_agree.index-1)))))
fig, ax = plt.subplots(figsize=(8,5))
sns.scatterplot(x=squared_log_returns_autocorr[both_tests_agree.index-1,0],␣
↪y=squared_log_returns_autocorr[both_tests_agree.index-1,1],␣
↪label="Statystycznie istotna autokorelacja kwadratu logarytmicznych␣
↪zwrotów", c="g", ax=ax)
sns.scatterplot(x=squared_log_returns_autocorr[not_significant,0],␣
↪y=squared_log_returns_autocorr[not_significant,1], label="Statystycznie␣
↪nieistotna autokorelacja kwadratu logarytmicznych zwrotów", c="r", ax=ax)
ax.set_xticks(squared_log_returns_autocorr[:,0])
ax.set_ylabel("Wartość autokorelacji")
ax.set_xlabel("Rząd korelogramu")
ax.set_ylim(-1.0, 1.0)
plt.show()
```

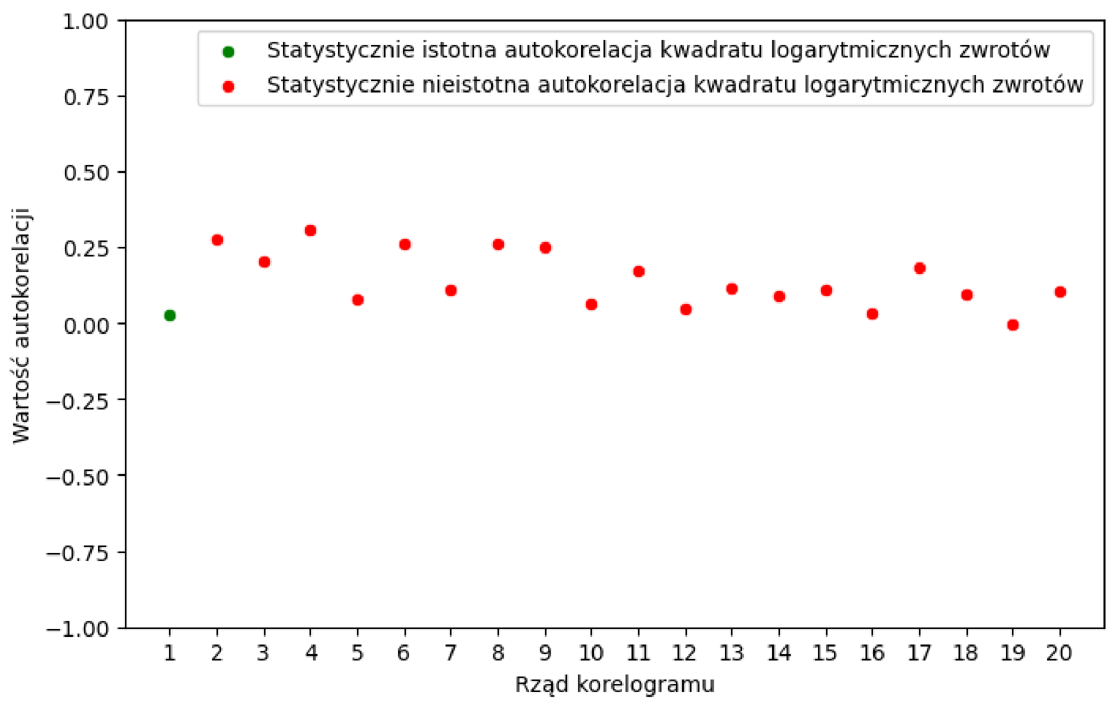

W przypadku kwadratów zwrotów logarytmicznych można mówić o jeszcze słabszej liniowej zależności między szeregiem kwadratów zwrotów, a nim samym przesuniętym o n-dni. Statystycznie istotna jest tylko wartość korelacji dla szeregu przesuniętego o jeden dzień. Dla tego przesunięcia wartość korelacji jest bliska zeru.

2 Podsumowanie

Szereg zwrotów logarytmicznych z akcji spółki Volkswagen w okresie 2018-2021 charakteryzuje się większą zmiennością niż wynikałoby to z rozkładu normalnego zwrotów. Jednocześnie średnia zwrotów osiąga wartość zbliżoną do zera przy dużym odchyleniu standardowym.